

Тематическое моделирование

7 апреля 2025 г.

1 Введение

Тематическое моделирование в литературе описывается с точки зрения задачи кластеризации текстовых коллекций. Перед нами большая коллекция текстов: это могут быть миллионы документов. Хотелось бы понять, какие темы есть в этих документах. Для начала определимся с тем что мы будем понимать под словом 'тема':

- тема — специальная терминология предметной области
- тема - набор часто совместно встречающихся терминов
- тема — семантически однородный кластер текстов

Более формально,

- тема — условное распределение на множестве терминов, $p(w|t)$ — вероятность термина w в теме t ;
- тематический профиль документа - условное распределение $p(t|d)$ - вероятность темы t в документе d .

То есть тема - просто частотный словарь на множестве слов (то, с какой частотой в этой теме появляется то или иное слово).

Например, тему по биологии от темы по математике мы отличаем по тому, с какой частотой употребляется специальная терминология в каждой теме. Второе, что нас будет интересовать - распределение по темам в каждом документе, и это то, что отличает задачу от классических задач кластеризации (говорят жесткая кластеризация и мягкая кластеризация). Кластеризация новостей - это очень популярная задача, и там, как правило, кластеризация жесткая, потому что новостное сообщение относится к какому-то событию или какой-то теме; если же говорить о кластеризации научных статей, то там кластеризация будет мягкой, потому что научная статья может относиться сразу к нескольким темам: много исследований бывают на стыке наук, а значит, нужно научиться не только выделять темы как распределение над словами, но ещё и научиться выделять темы в каждом документе, понимать, что документ может быть связан с несколькими темами.

2 Исследование задачи

Пусть у нас есть три конечных множества: W - слова, D - документы и T - темы. Предполагаем, что вся коллекция текстовых документов - это последовательность таких троек. Тематическая модель выявляет латентные темы по наблюдаемым распределениям слов $p(w|d)$ в документах. Когда автор писал термин w в документе d , он думал о теме t , и мы хотели бы выявить, о какой именно. По формуле полной вероятности:

$$p(w|d) = \sum_{t \in T} p(w|t)p(t|d)$$

(Здесь пользуемся гипотезой условной независимости: $p(w|d, t) = p(w|t)$, так как предполагаем, что порождение слов в документе не зависит от самого документа, а только от темы)

Будем решать задачу восстановления $p(w|t)$ и $p(t|d)$ по коллекции.

Дано: Коллекция текстовых документов:

- n_{dw} — частоты терминов в документах
- Эмпирическое распределение терминов:

$$\hat{p}(w|d) = \frac{n_{dw}}{n_d}, \quad \text{где } n_d = \sum_w n_{dw}$$

Найти: Параметры тематической модели:

$$p(w|d) = \sum_{t \in T} \phi_{wt} \theta_{td}$$

где:

- $\phi_{wt} = p(w|t)$ — распределение терминов в теме
- $\theta_{td} = p(t|d)$ — распределение тем в документе

Математическая формулировка: Задача представляет собой *стохастическое матричное разложение* (стохастическое, т.к. столбцы всех трех матриц - векторы, соответствующие дискретным вероятностным распределениям: каждый столбец нормирован, сумма элементов равна единице и не отрицательна):

$$\hat{\mathbf{P}} \approx \mathbf{\Phi} \mathbf{\Theta}$$

- $\hat{\mathbf{P}} = [\hat{p}(w|d)]$ — матрица эмпирических распределений (термины $\times$ документы)
- $\mathbf{\Phi} = [\phi_{wt}]$ — матрица тем (термины $\times$ темы)

- $\Theta = [\theta_{td}]$ — матрица распределений тем (темы $\times$ документы)

Чтобы строить вероятностные модели, можно воспользоваться методом максимума правдоподобия.

Правдоподобие -плотность распределения выборки $(d_i, w_i)_{i=1}^n$:

$$\prod_{i=1}^n p(d_i, w_i) \prod_{d \in D} \prod_{w \in d} p(d, w)^{n_{dw}}$$

Максимизация логарифма правдоподобия

$$\sum_{d \in D} \sum_{w \in d} n_{dw} \ln p(w, d) \rightarrow \max_{\Theta, \Phi}$$

приводит к задаче математического программирования:

$$\sum_{d \in D} \sum_{w \in d} n_{dw} \ln \sum_{t \in T} \phi_{wt} \theta_{td} \rightarrow \max_{\Theta, \Phi}$$

при ограничениях неотрицательности и нормировки

$\phi_{wt} \geq 0$; $\sum_{w \in W} \phi_{wt} = 1$; $\theta_{td} \geq 0$; $\sum_{t \in T} \theta_{td} = 1$;, n означает суммарную длину всей коллекции.

Плохая новость про эту задачу - она некорректно поставлена по Адамару: ее решение не единственное (точнее, существует бесконечное множество решений этой задачи). Мы ищем матричное разложение, которое определено с точностью до невырожденного преобразования.

Если (Φ, Θ) — решение, то для любой стохастической матрицы S размера $|T| \times |T|$ пара (Φ', Θ') также является решением: $\Phi' = \Phi S$, $\Theta' = S^{-1} \Theta$

При этом выполняется: $\Phi' \Theta' = (\Phi S)(S^{-1} \Theta) = \Phi \Theta$

Сохраняется значение функционала правдоподобия: $\mathcal{L}(\Phi', \Theta') = \mathcal{L}(\Phi, \Theta)$

Для приближённых решений: $\mathcal{L}(\Phi', \Theta') \geq \mathcal{L}(\Phi, \Theta) - \varepsilon$. Нужно применить регуляризацию, то есть сказать, какими ещё дополнительными критериям хотелось бы, чтобы обладали матрицы Φ , чтобы найти единственное устойчивое решение.

Максимизация логарифма правдоподобия с регуляризатором:

$$\sum_{d \in D} \sum_{w \in d} n_{dw} \ln \sum_{t \in T} \phi_{wt} \theta_{td} + R(\Theta, \Phi) \rightarrow \max_{\Theta, \Phi}, R(\Theta, \Phi) = \sum_i \tau_i R_i(\Theta, \Phi)$$

(Можем взять несколько регуляризаторов и сложить эти критерии с какими-то весовыми коэффициентами)

Покажем, что наша задача - ЕМ-алгоритм (метод простой итерации для системы уравнений), где

Е-шаг:

$$p_{tdw} \equiv p(t|d, w) = \text{norm}_{t \in T}(\phi_{wt} \theta_{td})$$

М-шаг:

$$\phi_{wt} = \text{norm}_{w \in W}(n_{wt} + \phi_{wt} \frac{\partial R}{\partial \phi_{wt}}), n_{wt} = \sum_{d \in D} n_{dw} p_{tdw}$$

$$\theta_{td} = \text{norm}_{t \in T}(n_{td} + \theta_{td} \frac{\partial R}{\partial \theta_{td}}), n_{td} = \sum_{w \in d} n_{dw} p_{tdw},$$

где $\text{norm}_{t \in T}(x_t) = \frac{\max(x_t, 0)}{\sum_{s \in T} \max(x_s, 0)}$ - операция нормировки вектора.

Решение может быть вырожденным для некоторых тем (столбцов матриц Φ) и документов (столбцов матрицы Θ).

Тема t вырождена, если для всех терминов $w \in W$

$$n_{wt} + \phi_{wt} \frac{\partial R}{\partial \phi_{wt}} \leq 0.$$

Если тема t вырождена, то $p(w|t) = \phi_{wt} \equiv 0$; это означает, что тема исключается из модели (происходит отбор тем).

Документ d вырожден, если для всех тем $t \in T$

$$n_{td} + \theta_{td} \frac{\partial R}{\partial \theta_{td}} \leq 0.$$

Если документ d вырожден, то $p(t|d) = \theta_{td} \equiv 0$; это означает, что модель не в состоянии описать данный документ.

Приведём доказательство корректности постановки такой задачи с помощью теоремы Каруша-Куна-Таккера.

Задача математического программирования:

$$\begin{cases} f(x) \rightarrow \min_x; \\ g_i(x) \leq 0, i = 1, \dots, m; \\ h_j(x) = 0, j = 1, \dots, k; \end{cases}$$

Необходимые условия:

Если x - точка локального минимума, то существуют множители $\mu_i, i = 1, \dots, m, j = 1, \dots, k$:

$$\begin{cases} \frac{\partial \mathcal{L}}{\partial x} = 0, \mathcal{L}(x; \mu, \lambda) = f(x) + \sum_{i=1}^m \mu_i g_i(x) + \sum_{j=1}^k \lambda_j h_j(x); \\ g_i(x) \leq 0, h_j(x) = 0; \text{ (исходные ограничения)} \\ \mu_i \geq 0; \text{ (двойственные ограничения)} \\ \mu_i g_i(x) = 0; \text{ (условие дополняющей нежёсткости)} \end{cases}$$

Вывод системы уравнений из условий Каруша-Куна-Таккера

1. Условия ККТ для ϕ_{wt} (для θ_{td} всё аналогично):

$$\sum_d n_{dw} \frac{\theta_{td}}{p(w|d)} + \frac{\partial R}{\partial \phi_{wt}} = \lambda_t - \mu_{wt}; \quad \mu_{wt} \geq 0; \quad \mu_{wt} \phi_{wt} = 0.$$

2. Умножим обе части равенства на ϕ_{wt} и выделим p_{tdw} :

$$\phi_{wt}\lambda_t = \sum_d n_{dw} \frac{\phi_{wt}\theta_{td}}{p(w|d)} + \phi_{wt} \frac{\partial R}{\partial \phi_{wt}} = n_{wt} + \phi_{wt} \frac{\partial R}{\partial \phi_{wt}}.$$

3. Если $\lambda_t \leq 0$, то тема t вырождена, $\phi_{wt} = 0$ для всех w .

4. Если $\lambda_t > 0$, то либо $\phi_{wt} = 0$, либо $n_{wt} + \phi_{wt} \frac{\partial R}{\partial \phi_{wt}} > 0$:

$$\phi_{wt}\lambda_t = \left(n_{wt} + \phi_{wt} \frac{\partial R}{\partial \phi_{wt}} \right)_+.$$

5. Суммируем обе части равенства по $w \in W$:

$$\lambda_t = \sum_{w \in W} \left(n_{wt} + \phi_{wt} \frac{\partial R}{\partial \phi_{wt}} \right)_+.$$

6. Подставим λ_t из (5) в (4), получим требуемое.

ЕМ-алгоритм — это чередование Е и М шагов до сходимости.

- **Е-шаг:** условные вероятности тем $p(t|d, w)$ для всех t, d, w вычисляются через ϕ_{wt} , θ_{td} по формуле Байеса:

$$p(t|d, w) = \frac{p(w, t|d)}{p(w|d)} = \frac{p(w|t)p(t|d)}{p(w|d)} = \frac{\phi_{wt}\theta_{td}}{\sum_s \phi_{ws}\theta_{sd}}.$$

- **М-шаг:** при $R = 0$ частотные оценки условных вероятностей вычисляются суммированием счётчика $n_{tdw} = n_{dw}p(t|d, w)$:

$$\begin{aligned} \phi_{wt} &= \frac{n_{wt}}{n_t}, & n_{wt} &= \sum_{d \in D} n_{tdw}, & n_t &= \sum_{w \in W} n_{wt}; \\ \theta_{td} &= \frac{n_{td}}{n_d}, & n_{td} &= \sum_{w \in d} n_{tdw}, & n_d &= \sum_{t \in T} n_{td}. \end{aligned}$$

Построение матрицы $X \in \mathbb{R}^{D \times W}$, где D — число документов, W — размер словаря; нахождение с помощью сингулярного разложения лучшей аппроксимации (в смысле квадратичного отклонения) ранга T :

$$X = \Theta\Phi, \quad \Theta \in \mathbb{R}^{D \times T}, \quad \Phi \in \mathbb{R}^{T \times W}.$$

будет называться **Latent semantic analysis (LSA)**.

Рассмотрим далее несколько известных моделей.

3 Probabilistic latent semantic analysis (PLSA)

Будем считать, что каждый документ x_d описывается распределением $p(t|d) = \theta_{td}$, а каждая тема — распределением $p(w|t) = \phi_{wt}$. Тогда совместное распределение на словах и документах можно записать как

$$p(w, d) = p(d)p(w|d) = p(d) \sum_{t=1}^T p(w|t)p(t|d).$$

Здесь мы, по сути, ввели скрытую переменную t , которая показывает, из какой темы было сгенерировано слово w документа x_d . Согласно данной модели, документ x_d генерируется по следующей схеме:

1. Выбираем тему $t \sim p(t|d)$;
2. Выбираем слово из данной темы $w \sim p(w|t)$;
3. Повторяем шаги 1 и 2, если текст не достиг требуемой длины.

Чтобы записать правдоподобие, следует смотреть на набор документов как на выборку пар «документ-слово». Неполное правдоподобие данной модели имеет вид

$$\sum_{d=1}^D \sum_{j=1}^{|x_d|} \log \sum_{t=1}^T \phi_{w_{dj}t} \theta_{td},$$

где w_{dj} — j -е по порядку слово из документа x_d . Если для каждой пары «документ-слово» (d, w_{dj}) известно, из какой темы t_{dj} оно сгенерировано, то можно записать полное правдоподобие:

$$\sum_{d=1}^D \sum_{j=1}^{|x_d|} \sum_{t=1}^T [t_{dj} = t] \log \phi_{w_{dj}t} \theta_{td}.$$

Мы уже знаем, что для обучения таких моделей можно воспользоваться ЕМ-алгоритмом. На Е-шаге оценим апостериорные распределения на скрытых переменных по формуле Байеса:

$$p(t_{dj}|d, w_{dj}) = \frac{p(w_{dj}|t_{dj})p(t_{dj}|d)}{p(w_{dj}|d)} = \frac{\phi_{w_{dj}t_{dj}}\theta_{t_{dj}d}}{p(w_{dj}|d)}$$

На М-шаге найдём максимум матожидания полного правдоподобия по скрытым переменным:

$$\begin{aligned} \phi_{wt} &= \frac{\sum_{d=1}^D n_{dw} p(t|d, w)}{\sum_{w=1}^W \sum_{d=1}^D n_{dw} p(t|d, w)}; \\ \theta_{td} &= \frac{\sum_{w=1}^W n_{dw} p(t|d, w)}{\sum_{t=1}^T \sum_{w=1}^W n_{dw} p(t|d, w)}. \end{aligned}$$

Здесь n_{dw} — число вхождений слова w в документ x_d .

Полученная в итоге работы ЕМ-алгоритма модель будет интерпретируемой — можно изучать, насколько сильно та или иная тема представлена в документе, или насколько то или иное слово характерно для темы.

С точки зрения введения регуляризации можно заметить, что $R(\Phi, \Theta) = 0$, и на М-шаге происходит нормировка по w и t соответственно:

$$\phi_{wt} = \text{norm}_w(n_{wt})$$

$$\theta_{td} = \text{norm}_t(n_{td})$$

Недостатки PLSA

- Переобучение модели:
 - Число параметров растёт как $O(|D| \cdot |T| + |W| \cdot |T|)$
 - Слишком большая ёмкость модели приводит к переобучению
- Отсутствие контроля разреженности:
 - Если $\phi_{wt} = 0$ на инициализации, то $\phi_{wt} = 0$ и в финальной модели
 - Аналогично для θ_{td} : $\theta_{td} = 0 \Rightarrow \theta_{td} = 0$ в результате
- Проблема новых слов:
 - Для слов с нулевой частотой: $n_w = 0 \Rightarrow \hat{p}(w|d) = 0$ для всех $t \in T$
 - Невозможность корректной оценки вероятности неизвестных слов

4 Latent Dirichlet Allocation (LDA)

Модель PLSA не является полной — распределения ϕ_t и θ_d считаются параметрами, не предполагается, что они тоже генерируются из некоторых распределений. Значит, с помощью данной модели не получится описать процесс порождения набора документов «с нуля». Более того, в PLSA отсутствует регуляризация, из-за чего модель может слишком сильно подогнаться под данные на небольших выборках.

Чтобы устранить два указанных недостатка, введём априорные распределения на векторах ϕ_t и θ_d . Для этого хорошо подходит симметричное распределение Дирихле, которое задано на множестве всех дискретных распределений с фиксированным числом исходов.

Пусть вектор-столбцы параметров модели: $\phi_t = (\phi_{wt})_{w \in W}$ и $\theta_d = (\theta_{td})_{t \in T}$ - генерируются распределениями Дирихле с параметрами $\alpha \in \mathbb{R}^{|T|}$ и $\beta \in \mathbb{R}^{|W|}$:

Плотность распределения Дирихле для вектора слов в теме:

$$\text{Dir}(\phi_t|\beta) = \frac{\Gamma(\beta_0)}{\prod_{w \in W} \Gamma(\beta_w)} \prod_{w \in W} \phi_{wt}^{\beta_w - 1},$$

где $\phi_{wt} > 0$ для всех $w \in W$, $\beta_0 = \sum_{w \in W} \beta_w$, $\beta_w > 0$ для всех $w \in W$.

Плотность распределения Дирихле для вектора тем в документе:

$$\text{Dir}(\theta_d|\alpha) = \frac{\Gamma(\alpha_0)}{\prod_{t \in T} \Gamma(\alpha_t)} \prod_{t \in T} \theta_{td}^{\alpha_t - 1},$$

где $\theta_{td} > 0$ для всех $t \in T$, $\alpha_0 = \sum_{t \in T} \alpha_t$, $\alpha_t > 0$ для всех $t \in T$.

Совместное правдоподобие данных и параметров модели:

$$\ln \prod_{d \in D} \prod_{w \in d} p(w, d|\Phi, \Theta)^{n_{dw}} \prod_{t \in T} \text{Dir}(\phi_t|\beta) \prod_{d \in D} \text{Dir}(\theta_d|\alpha) \rightarrow \max_{\Phi, \Theta}$$

Логарифм априорного распределения выступает в качестве регуляризатора:

$$R(\Phi, \Theta) = \sum_{t \in T} \sum_{w \in W} (\beta_w - 1) \ln \phi_{wt} + \sum_{d \in D} \sum_{t \in T} (\alpha_t - 1) \ln \theta_{td}$$

М-шаг — сглаженные (или разреженные) частотные оценки:

$$\phi_{wt} = \text{norm}_w(n_{wt} + \beta_w - 1) \quad (1)$$

$$\theta_{td} = \text{norm}_t(n_{td} + \alpha_t - 1) \quad (2)$$

- При $\beta_w > 1$, $\alpha_t > 1$ — эффект сглаживания распределений
- При $0 < \beta_w < 1$, $0 < \alpha_t < 1$ — слабое разреживание распределений
- При $\beta_w = 1$, $\alpha_t = 1$ — априорное распределение становится равномерным (вырожденный случай PLSA)

Полезным свойством является то, что распределение Дирихле способно порождать как сильно разреженные распределения, так и сильно сконцентрированные. После введения априорного распределения модель становится достаточно сложной для вывода. Как правило, для её обучения применяют техники вариационного вывода или семплирование Гиббса.

Почему именно распределение Дирихле?

- Оно способно порождать разреженные векторы,

- Имеет параметры, управляющие степенью разреженности,
- Описывает кластерные структуры на симплексе,
- Математически удобно для байесовского вывода.

Недостатки Latent Dirichlet Allocation

- Проблемы теоретического обоснования:
 - Слабые лингвистические основания выбора именно распределения Дирихле
 - Эвристический характер предположения $p(\phi_t|\beta) = \text{Dir}(\beta)$
- Вычислительная сложность:
 - Оригинальный метод требует интегрирования по пространству параметров:

$$p(w|d) = \int \int p(w|\phi)p(\phi|\beta)p(\theta|\alpha)d\phi d\theta$$

- Необходимость использования приближённых методов (VB, MCMC)
- Проблемы регуляризации:
 - По умолчанию реализует сглаживание ($\beta_w > 1$)
 - Для разреживания ($\beta_w < 1$) требуется специальная настройка
- Эмпирические ограничения:
 - На больших корпусах разница с PLSA статистически незначима:

$$\Delta\mathcal{L} = \mathcal{L}_{LDA} - \mathcal{L}_{PLSA} \approx 0 \quad \text{при } |D| \rightarrow \infty$$

5 Оценивание качества

Правдоподобие и перплексия (perplexity)

Правдоподобие языковой модели $p(w|d)$ (чем выше, тем лучше):

$$\mathcal{L}(\Phi, \Theta) = \sum_{d \in D} \sum_{w \in d} n_{dw} \ln p(w|d), \quad p(w|d) = \sum_t \phi_{wt} \theta_{td}$$

Перплексия языковой модели $p(w|d)$ (чем меньше, тем лучше):

$$P(D) = \exp \left(-\frac{1}{n} \sum_{d \in D} \sum_{w \in d} n_{dw} \ln p(w|d) \right), \quad n = \sum_{d \in D} \sum_{w \in d} n_{dw}$$

Интерпретация перплексии:

- если распределение $p(w|d) = \frac{1}{|W|}$ равномерное, то $P = |W|$
- мера различности или неопределённости слов в тексте
- коэффициент ветвления (branching factor) текста

Перплексия тестовой коллекции D' (hold-out perplexity)

$$P(D') = \exp \left(-\frac{1}{n''} \sum_{d \in D'} \sum_{w \in d''} n_{dw} \ln p(w|d) \right), \quad n'' = \sum_{d \in D'} \sum_{w \in d''} n_{dw}$$

$d = d' \cup d''$ — случайное разбиение тестового документа на две половины равной длины;

Параметры ϕ_{wt} оцениваются по обучающей коллекции D ;

Параметры θ_{td} оцениваются по первой половине d' ;

Перплексия вычисляется по второй половине d'' .

Интерпретируемость тем

Тема считается **интерпретируемой**, если по топовым словам темы эксперт может определить, о чём эта тема, и дать ей название.

Методы оценки интерпретируемости:

• Экспертные оценки:

- интерпретируемость темы по балльной шкале
- каждую тему оценивают несколько экспертов

• Метод интрузий (intrusion):

- в список топовых слов внедряется лишнее слово
- измеряется доля ошибок экспертов при его определении

Автоматическая мера интерпретируемости

Требуется автоматически вычисляемая мера интерпретируемости, коррелирующая с экспертными оценками.

Такой мерой оказалась *когерентность* (согласованность, *coherence*).

Когерентность (согласованность) темы t по k топовым словам

$$PMI_t = \frac{2}{k(k-1)} \sum_{i=1}^{k-1} \sum_{j=i+1}^k PMI(w_i, w_j)$$

где w_i — i -й термин в порядке убывания ϕ_{wt} .

$$PMI(u, v) = \ln \frac{|D| N_{uv}}{N_u N_v} \quad (\text{поточечная взаимная информация, pointwise mutual information})$$

- N_{uv} — число документов, в которых термины u , v хотя бы один раз встречаются рядом (в окне 10 слов)
- N_u — число документов, в которых u встретился хотя бы 1 раз
- $|D|$ — общее количество документов в коллекции

Список литературы

- [1] Лекция К.В. Воронцова по тематическому моделированию
- [2] Семинар Соколова Е.А.
- [3] Воронцов К. В., Потапенко А. А. Модификации ЕМ-алгоритма для вероятностного тематического моделирования. Машинное обучение и анализ данных. — 2013
- [4] Тематическое моделирование