

Математические Методы Распознавания образов, ВМК МГУ

Optimal Control Reinforcement Learning

Автор: Афанасьев Глеб

1 Введение

Данный блок семинаров по ММРО является развитием такой области как оптимальное управление в сторону применения алгоритмов машинного обучения.

2 Задача оптимального управления и методы ее решения

§2.1 Постановка задачи оптимального управления, непрерывный и дискретный случаи

Начнем с формулировки целевой задачи данного блока: задачи оптимального управления. В общем случае, она заключается в поиске управления и порождаемой им траектории управляемого объекта, оптимальных в смысле заданного функционала и удовлетворяющих ограничениям на динамику. В общем случае, данная задача выписывается в следующем виде:

$$J(x(t), u(t)) = \int_{t_0}^{t_1} l(x(t), u(t)) dt + l_F(x(t_1)) \rightarrow \min_{x, u}$$
$$\dot{x} = f(x(t), u(t))$$

Здесь l - функция, определяющая потери, получающиеся, если в состоянии x управляемый объект выполнит действие u , l_F - функция, определяющая потери в конечном состоянии. В таком виде решением задачи является пара функций $x^*(t)$, $u^*(t)$, где $x^*(t)$ - оптимальная траектория, $u^*(t)$ - порождающее её оптимальное управление.

На практике, в силу дискретности вычислительных систем, мы чаще имеем дело с дискретным вариантом данной задачи:

$$J(x, u) = \sum_{n=1}^{N-1} l(x_n, u_n) + l_F(x_N) \rightarrow \min_{x_{1:N}, u_{1:N-1}}$$
$$x_{n+1} = f(x_n, u_n)$$

И задача таким образом сводится к поиску оптимальной траектории вида $((x_1, u_1), (x_2, u_2), \dots, (x_{N-1}, u_{N-1}), (x_N))$, минимизирующей функционал J и удовлетворяющей ограничениям на динамику. Важно помнить, что дискретной тут является только динамика, в то время как функции потерь l , l_F и f могут быть непрерывными.

Не трудно заметить, что выписанная выше задача представляет собой оптимизационную задачу с ограничениями типа "равенство".

Поиск решения этой задачи будет построен следующим образом:

1. В части 2.3 будет кратко воспроизведена теория исследования данной задачи через механизм функций Беллмана [1][2].
2. В разделе 3 будет рассмотрен практический алгоритм решения задачи в упрощенном случае, где предполагается линейный вид функции $f(x, u)$ и квадратичный вид функций $l(x, u)$ и $l_F(x, u)$. Задача оптимального управления с такими ограничениями носит название линейно-квадратичный регулятор (Linear Quadratic Regulator, LQR)
3. Затем, в разделе 4 будут сняты ограничения на вид функций динамики и потерь, и задача будет решена для произвольных функций, однако с ограничениями на пространство состояний X . В литературе рассмотренные методы носят названия Value Iteration [3] и Policy Iteration [3].
4. Наконец, в разделе 5 будет снято ограничение на пространство состояний X и рассмотрен метод, носящий в литературе название Advanced Actor Critic (A2C) [4].
5. Раздел 6 будет содержать выводы из лекций и некоторые дополнительные рассуждения

§2.2 Уравнение Беллмана

Рассмотрим наиболее популярную в наше время теорию исследования задач ОУ: теорию уравнений Беллмана. Более подробно вы её рассматривали на лекциях по оптимальному управлению [2].

2.2.1 Уравнение Беллмана

Рассмотрим общую задачу минимизации:

$$f(x) \rightarrow \min_{x \in X} \quad (2.1)$$

в теории уравнений Беллмана задача ОУ рассматривается как расширение задачи (2.1) путем добавления в нее нового параметра. Пока обозначим его как $\alpha \in \Lambda$. Теперь новая задача выглядит следующим образом:

$$F(x, \alpha) \rightarrow \min_{x \in X(\alpha)}$$

Очевидно что при каком-то $\alpha = \alpha_0$ мы приходим к оригинальной задаче:

$$F(x, \alpha_0) = f(x)$$

$$X(\alpha_0) = X$$

Введем функцию следующего вида:

$$T(\alpha) = \min_{x \in X(\alpha)} F(x, \alpha), \forall \alpha \in \Lambda$$

Функцией Беллмана называется функция T взятая со знаком минус:

$$V(\alpha) = -T(\alpha)$$

Теперь вспомним что изначально у нас стояла задача минимизации с ограничениями на динамику:

$$\begin{aligned} J(x(t), u(t)) &= \int_{t_0}^{t^1} l(x(t), u(t)) dt \rightarrow \min_{x, u} \\ \dot{x} &= f(x(t), u(t)) \end{aligned}$$

Помимо двух выписанных выше уравнений, зачастую мы хотим задать точки начала и конца траектории: $x(t_0) = x_0, x(t_1) = x_1$

Введем параметризацию данной задачи через точку начала траектории.

То есть от исходной задачи мы переходим к задаче

$$\begin{cases} J(x(t), u(t)) = \int_{t_0}^{t^1} l(x(t), u(t)) dt \\ \dot{x} = f(x(t), u(t)) \\ x(t_0) = \alpha \end{cases}$$

Конечное условие зачастую задается неявно через оптимизируемый функционал.

Соответственно, для такой задачи функция Беллмана примет следующий вид:

$$V(\alpha) = -\min_{x, u \in X_\alpha} J(x, u, \alpha)$$

Здесь и далее по конспекту следует помнить, что несмотря на то что явно мы не прописываем вхождение ограничений на динамику в функцию Беллмана, они (в отличие от советской теории ОУ с принципом максимума Понтрягина) входят туда неявно через договоренность, что траектории x, u в функции Беллмана мы рассматриваем только связанные ограничениями на динамику.

Для дальнейших рассуждений нам потребуется сделать следующие предположения о функции Беллмана и решаемой задаче:

1. Функция Беллмана существует для всех рассматриваемых α
2. $V(\alpha) \in C^1(\alpha)$
3. Любой "хвост" оптимальной траектории - оптимален

Первые два пункта обычно гарантируются видом конкретной задачи.

Рассмотрим подробнее пункт 3. По сути, он означает что если мы имеем оптимальное управление и траекторию в виде функций от времени $u^*(t), x^*(t)$ для начальной точки $x(t_0) = x_0$ и конечной точки x_1 , то это же управление будет оптимальным и для такой же задачи с начальной точкой $x_{0.5}$, где $x_{0.5}$ - точка, лежащая на оптимальной траектории $x^*(t)$.

Для рассматриваемой задачи он проверяется тривиально от противного: зафиксируем точку на траектории $x_{0.5}$ и предположим что из нее существует более оптимальное управление для достижения конечной точки x_1 . Обозначим его за $u'(t), x'(t)$ (рис 1). То есть $\int_{\tau}^{t_1} l(x'(t), u'(t))dt < \int_{\tau}^{t_1} l(x^*(t), u^*(t))dt$, где τ - момент времени когда объект оказался в точке $x_{0.5}$.




Рис. 1.

Тогда совершенно очевидно, что управление вида

$$u(t) = \begin{cases} u^*(t), t < \tau \\ u'(t), t \geq \tau \end{cases}$$

Будет более оптимальным в смысле оптимизируемого функционала, так как $\int_{t_0}^{\tau} l(x^*(t), u^*(t))dt + \int_{\tau}^{t_1} l(x'(t), u'(t))dt < \int_{t_0}^{t_1} l(x^*(t), u^*(t))dt$. Значит, управление $u^*(t)$ не оптимально, и мы приходим к противоречию с условием.

Далее будем считать, что предположения 1-3 выполнены.

Теперь рассмотрим оптимальное управление $u(t)$ для задачи выше. Оговоримся, что на курсе по оптимальному управлению было принято оперировать оптимальными парами $(x(t), u(t))$, однако, поскольку управление порождает траекторию, мы будем в основном ссылаться именно на само управление как на искомый объект, имея ввиду что он порождает соответствующую ему траекторию.

Возьмем промежуток времени Δt : $t_0 + \Delta t < t_1$.

Получаем:

$$T(\alpha) = \int_{t_0}^{t_0+\Delta t} l(x(t), u(t))dt + \int_{t_0+\Delta t}^{t_1} l(x(t), u(t))dt = \int_{t_0}^{t_0+\Delta t} l(x(t), u(t))dt + T(x(t_0+\Delta t))$$

Значит,

$$V(x(t_0 + \Delta t)) - V(\alpha) = L(t_0 + \Delta t) - L(t_0)$$

где $L(t)$ - первообразная по t для $l(x(t), u(t))$.

Делим правую и левую части на Δt и устремляем Δt к 0. Учитывая что с помощью α мы параметризовали значение $x(t_0)$ получаем:

$$\dot{V}(\alpha) = \dot{L}(t_0) = l(\alpha, u_0)$$

Вспоминаем что α может быть произвольным и должно удовлетворять заданной динамике

$$\dot{V}(\alpha) = \langle V'_x, \dot{x}(t) \rangle = \langle V'_x, f(x, u) \rangle = l(x, u)$$

$$\langle V'_x, f(x, u) \rangle - l(x, u) = 0$$

И в итоге получаем необходимое условие оптимальности:

$$\langle V'_x, f(x, u) \rangle - l(x, u) = 0$$

Теперь предположим, что мы сначала на протяжении времени Δt двигаемся каким-то случайным управлением v , а потом включаем оптимальное. Для функции T будет справедливо следующее неравенство:

$$T(\alpha) \leq \int_{t_0}^{t_0 + \Delta t} l(x(t), v(t)) dt + T(y(t_0 + \Delta t))$$

Где $y(t_0 + \Delta t)$ - точка, в которой окажется управляемый объект при включении управления v в точке α за время Δt

Переносим функцию T в левую часть и делим на Δt , получаем:

$$\frac{V(y(t_0 + \Delta t)) - V(\alpha)}{\Delta t} \leq \frac{L(t_0 + \Delta t) - L(t_0)}{\Delta t}$$

Раскладывая $y(t_0 + \Delta t)$ в ряд Тейлора, получаем:

$$y(t_0 + \Delta t) = y(t_0) + \dot{y}(t_0)\Delta t + \bar{o}(\Delta t) = \alpha + f(\alpha, v(t_0))\Delta t + \bar{o}(\Delta t)$$

И неравенство можно переписать в виде:

$$\langle V'_x, f(x, v(t)) \rangle - l(x, v) \leq 0 \tag{2.2}$$

То есть, выражение из левой части (2.2) для произвольного управления меньше 0, а для оптимального равно 0. Таким образом, мы получаем уравнение Беллмана:

$$\max_{u(t)} [\langle V'_x, f(x(t), u(t)) \rangle - l(x(t), u(t))] = 0$$

2.2.2 Переход к дискретному случаю

Так как в наше время расчеты управляющих действий и траекторий ведутся на компьютерах, где время дискретно, мы переходим к дискретной постановке задачи и рассмотрим вид изучаемой теории в дискретном случае. Напомним, что исходная задача примет вид:

$$J = \sum_{n=0}^{N-1} l(x_n, u_n) + l_F(x_N) \rightarrow \min_u$$

$$x_{n+1} = f(x_n, u_n)$$

Заметим, что далеко не всегда у нас стоит требование на фиксированное количество шагов, поэтому N часто не фиксировано и в некоторых задачах может равняться бесконечности. В таких случаях слагаемое l_F не имеет смысла.

В таких терминах, функция Беллмана $V(x)$ будет равняться минимальным по всевозможным управлениям общим потерям при условии, что мы начали движение из точки x . Переходную функцию $T(x)$ на практике пропускают.

$$V(x) = \min_u \sum_{n=0}^{+\infty} l(x_n, u_n), x_0 = x$$

Здесь суммирование идет до бесконечности, однако в случае конечных траекторий мы можем просто дополнить нулями оставшиеся награды.

Далее, вспомним как мы выводили уравнение Беллмана. Непрерывность там возникала когда мы переходили к пределу по $\Delta t \rightarrow 0$. Распишем вывод для дискретного случая когда на Δt делить не нужно:

$$V(x_k) - V(x_{k+1}) = l(x_k, u_k)$$

Так как минимально возможное количество шагов во времени равняется 1 шагу, мы получаем левую часть уравнения. Правая часть следует из того что за 1 шаг мы получим только потери за этот шаг. Вообще говоря, ровно 1 шаг делать не обязательно. Так как изначально требований на Δt не было, мы можем выписать уравнение как

$$V(x_k) - V(x_{k+n}) = \sum_{i=k}^{k+n} l(x_i, u_i)$$

2.2.3 Стохастический дискретный случай

Мы вывели дискретное уравнение Беллмана. Однако во всех выкладках мы предполагали окружающую среду строго детерминированной. В реальных задачах такое встречается редко. В большинстве случаев приходится иметь дело с некоторым элементом случайности, когда динамика принимает вид

$$x_{n+1} = f(x_n, u_n, \epsilon)$$

где ϵ - некоторый случайный параметр, взятый из распределения $p(\epsilon)$

В таком случае, функция Беллмана примет вид минимальных ожидаемых потерь с учетом случайности динамики. То есть

$$V(x) = \min_u \mathbb{E}_{p(\epsilon)} \sum_{n=0}^{+\infty} l(x_n, u_n)$$

И уравнение Беллмана примет вид

$$\begin{aligned} V(x_k) &= \min_u \mathbb{E}_{p(\epsilon)} \sum_{n=k}^{+\infty} l(x_n, u_n) = \min_u \mathbb{E}_{p(\epsilon)} [l(x_k, u_k) + \sum_{n=k+1}^{+\infty} l(x_n, u_n)] = \\ &= \min_u \mathbb{E}_{p(\epsilon)} [l(x_k, u_k)] + \min_u \mathbb{E}_{p(\epsilon)} \left[\sum_{n=k+1}^{+\infty} l(x_n, u_n) \right] = l(x_k, u_k) + \mathbb{E}_{p(\epsilon)} V(x_{k+1}) \end{aligned}$$

Последнее равенство имеет место, так как мы предполагаем u_k оптимальным. Таким образом, было выведено уравнение Беллмана в том виде, в котором его можно встретить в большинстве современной литературы [4], [5], [6], [7].

—TO BE CONTINUED—

Список литературы

- [1] *Richard Bellman. Dynamic programming* <https://djvu.online/file/PtjL5vzLMF7dH?ysclid=m9bwfqwbna925964072>
- [2] *Лекция Орлова про уравнение Беллмана* <https://www.youtube.com/watch?v=dZcL6qi6lqw&list=LL&index=91>
- [3] *Richard S. Sutton and Andrew G. Barto, Reinforcement Learning, глава 4* https://drive.google.com/file/d/1Z4W_-0IaMNpZnhnMkqcDVM_EA79GFJo-/view
- [4] *Asynchronous Methods for Deep Reinforcement Learning* <https://arxiv.org/pdf/1602.01783>
- [5] *Trust Region Policy Optimization* <https://arxiv.org/pdf/1502.05477>
- [6] *Proximal Policy Optimization Algorithms* <https://arxiv.org/pdf/1707.06347>
- [7] *Soft Actor-Critic* <https://arxiv.org/pdf/1801.01290>
- [8] *Riccati Equations in Optimal Control Theory* <http://www.facweb.iitkgp.ac.in/~bibhas/Riccati%20Equations%20in%20Optimal%20Control%20Theory.pdf>
- [9] *New Forms of Riccati Equations and the Further Results of the Optimal Control for Linear Discrete-Time Systems* https://www.researchgate.net/publication/286129306_New_Forms_of_Riccati_Equations_and_the_Further_Results_of_the_Optimal_Control_for_Linear_Discrete-Time_Systems?enrichId=rgreq-5bdd803e3a1500ee1dfe7ba803235e24-XXX&enrichSource=Y292ZXJQYWdlOzI4NjEyOTMwNjBUzo3NTE1MDYwMTgwMTMxODhAMTU1NjE4NDQwNTUONG%3D%3D&el=1_x_3&_esc=publicationCoverPdf