

Математические Методы Распознавания образов, ВМК МГУ

Optimal Control Reinforcement Learning

Автор: Афанасьев Глеб

1 Введение

Данный блок семинаров по ММРО является развитием такой области как оптимальное управление в сторону применения алгоритмов машинного обучения.

2 Задача оптимального управления и методы ее решения

§2.1 Постановка задачи оптимального управления, непрерывный и дискретный случаи

Начнем с формулировки целевой задачи данного блока: задачи оптимального управления. В общем случае, она заключается в поиске управления и порождаемой им траектории управляемого объекта, оптимальных в смысле заданного функционала и удовлетворяющих ограничениям на динамику. В общем случае, данная задача выписывается в следующем виде:

$$J(x(t), u(t)) = \int_{t_0}^{t_1} l(x(t), u(t)) dt + l_F(x(t_1)) \rightarrow \min_{x, u}$$
$$\dot{x} = f(x(t), u(t))$$

Здесь l - функция, определяющая потери, получающиеся, если в состоянии x управляемый объект выполнит действие u , l_F - функция, определяющая потери в конечном состоянии. В таком виде решением задачи является пара функций $x^*(t)$, $u^*(t)$, где $x^*(t)$ - оптимальная траектория, $u^*(t)$ - порождающее её оптимальное управление.

На практике, в силу дискретности вычислительных систем, мы чаще имеем дело с дискретным вариантом данной задачи:

$$J(x, u) = \sum_{n=1}^{N-1} l(x_n, u_n) + l_F(x_N) \rightarrow \min_{x_{1:N}, u_{1:N-1}}$$
$$x_{n+1} = f(x_n, u_n)$$

И задача таким образом сводится к поиску оптимальной траектории вида $((x_1, u_1), (x_2, u_2), \dots, (x_{N-1}, u_{N-1}), (x_N))$, минимизирующей функционал J и удовлетворяющей ограничениям на динамику. Важно помнить, что дискретной тут является только динамика, в то время как функции потерь l , l_F и f могут быть непрерывными.

Не трудно заметить, что выписанная выше задача представляет собой оптимизационную задачу с ограничениями типа "равенство".

Поиск решения этой задачи будет построен следующим образом:

1. В части 2.3 будет кратко воспроизведена теория исследования данной задачи через механизм функций Беллмана [1][2].
2. В разделе 3 будет рассмотрен практический алгоритм решения задачи в упрощенном случае, где предполагается линейный вид функции $f(x, u)$ и квадратичный вид функций $l(x, u)$ и $l_F(x, u)$. Задача оптимального управления с такими ограничениями носит название линейно-квадратичный регулятор (Linear Quadratic Regulator, LQR)
3. Затем, в разделе 4 будут сняты ограничения на вид функций динамики и потерь, и задача будет решена для произвольных функций, однако с ограничениями на пространство состояний X . В литературе рассмотренные методы носят названия Value Iteration [3] и Policy Iteration [3].
4. Наконец, в разделе 5 будет снято ограничение на пространство состояний X и рассмотрен метод, носящий в литературе название Advanced Actor Critic (A2C) [4].
5. Раздел 6 будет содержать выводы из лекций и некоторые дополнительные рассуждения

§2.2 Уравнение Беллмана

Рассмотрим наиболее популярную в наше время теорию исследования задач ОУ: теорию уравнений Беллмана. Более подробно вы её рассматривали на лекциях по оптимальному управлению [2].

2.2.1 Уравнение Беллмана

Рассмотрим общую задачу минимизации:

$$f(x) \rightarrow \min_{x \in X} \quad (2.1)$$

в теории уравнений Беллмана задача ОУ рассматривается как расширение задачи (2.1) путем добавления в нее нового параметра. Пока обозначим его как $\alpha \in \Lambda$. Теперь новая задача выглядит следующим образом:

$$F(x, \alpha) \rightarrow \min_{x \in X(\alpha)}$$

Очевидно что при каком-то $\alpha = \alpha_0$ мы приходим к оригинальной задаче:

$$F(x, \alpha_0) = f(x)$$

$$X(\alpha_0) = X$$

Введем функцию следующего вида:

$$T(\alpha) = \min_{x \in X(\alpha)} F(x, \alpha), \forall \alpha \in \Lambda$$

Функцией Беллмана называется функция T взятая со знаком минус:

$$V(\alpha) = -T(\alpha)$$

Теперь вспомним что изначально у нас стояла задача минимизации с ограничениями на динамику:

$$\begin{aligned} J(x(t), u(t)) &= \int_{t_0}^{t^1} l(x(t), u(t)) dt \rightarrow \min_{x, u} \\ \dot{x} &= f(x(t), u(t)) \end{aligned}$$

Помимо двух выписанных выше уравнений, зачастую мы хотим задать точки начала и конца траектории: $x(t_0) = x_0, x(t_1) = x_1$

Введем параметризацию данной задачи через точку начала траектории.

То есть от исходной задачи мы переходим к задаче

$$\begin{cases} J(x(t), u(t)) = \int_{t_0}^{t^1} l(x(t), u(t)) dt \\ \dot{x} = f(x(t), u(t)) \\ x(t_0) = \alpha \end{cases}$$

Конечное условие зачастую задается неявно через оптимизируемый функционал.

Соответственно, для такой задачи функция Беллмана примет следующий вид:

$$V(\alpha) = -\min_{x, u \in X_\alpha} J(x, u, \alpha)$$

Здесь и далее по конспекту следует помнить, что несмотря на то что явно мы не прописываем вхождение ограничений на динамику в функцию Беллмана, они (в отличие от советской теории ОУ с принципом максимума Понтрягина) входят туда неявно через договоренность, что траектории x, u в функции Беллмана мы рассматриваем только связанные ограничениями на динамику.

Для дальнейших рассуждений нам потребуется сделать следующие предположения о функции Беллмана и решаемой задаче:

1. Функция Беллмана существует для всех рассматриваемых α
2. $V(\alpha) \in C^1(\alpha)$
3. Любой "хвост" оптимальной траектории - оптимален

Первые два пункта обычно гарантируются видом конкретной задачи.

Рассмотрим подробнее пункт 3. По сути, он означает что если мы имеем оптимальное управление и траекторию в виде функций от времени $u^*(t), x^*(t)$ для начальной точки $x(t_0) = x_0$ и конечной точки x_1 , то это же управление будет оптимальным и для такой же задачи с начальной точкой $x_{0.5}$, где $x_{0.5}$ - точка, лежащая на оптимальной траектории $x^*(t)$.

Для рассматриваемой задачи он проверяется тривиально от противного: зафиксируем точку на траектории $x_{0.5}$ и предположим что из нее существует более оптимальное управление для достижения конечной точки x_1 . Обозначим его за $u'(t), x'(t)$ (рис 1). То есть $\int_{\tau}^{t_1} l(x'(t), u'(t))dt < \int_{\tau}^{t_1} l(x^*(t), u^*(t))dt$, где τ - момент времени когда объект оказался в точке $x_{0.5}$.




Рис. 1.

Тогда совершенно очевидно, что управление вида

$$u(t) = \begin{cases} u^*(t), t < \tau \\ u'(t), t \geq \tau \end{cases}$$

Будет более оптимальным в смысле оптимизируемого функционала, так как $\int_{t_0}^{\tau} l(x^*(t), u^*(t))dt + \int_{\tau}^{t_1} l(x'(t), u'(t))dt < \int_{t_0}^{t_1} l(x^*(t), u^*(t))dt$. Значит, управление $u^*(t)$ не оптимально, и мы приходим к противоречию с условием.

Далее будем считать, что предположения 1-3 выполнены.

Теперь рассмотрим оптимальное управление $u(t)$ для задачи выше. Оговоримся, что на курсе по оптимальному управлению было принято оперировать оптимальными парами $(x(t), u(t))$, однако, поскольку управление порождает траекторию, мы будем в основном ссылаться именно на само управление как на искомый объект, имея ввиду что он порождает соответствующую ему траекторию.

Возьмем промежуток времени Δt : $t_0 + \Delta t < t_1$.

Получаем:

$$T(\alpha) = \int_{t_0}^{t_0+\Delta t} l(x(t), u(t))dt + \int_{t_0+\Delta t}^{t_1} l(x(t), u(t))dt = \int_{t_0}^{t_0+\Delta t} l(x(t), u(t))dt + T(x(t_0+\Delta t))$$

Значит,

$$V(x(t_0 + \Delta t)) - V(\alpha) = L(t_0 + \Delta t) - L(t_0)$$

где $L(t)$ - первообразная по t для $l(x(t), u(t))$.

Делим правую и левую части на Δt и устремляем Δt к 0. Учитывая что с помощью α мы параметризовали значение $x(t_0)$ получаем:

$$\dot{V}(\alpha) = \dot{L}(t_0) = l(\alpha, u_0)$$

Вспоминаем что α может быть произвольным и должно удовлетворять заданной динамике

$$\dot{V}(\alpha) = \langle V'_x, \dot{x}(t) \rangle = \langle V'_x, f(x, u) \rangle = l(x, u)$$

$$\langle V'_x, f(x, u) \rangle - l(x, u) = 0$$

И в итоге получаем необходимое условие оптимальности:

$$\langle V'_x, f(x, u) \rangle - l(x, u) = 0$$

Теперь предположим, что мы сначала на протяжении времени Δt двигаемся каким-то случайным управлением v , а потом включаем оптимальное. Для функции T будет справедливо следующее неравенство:

$$T(\alpha) \leq \int_{t_0}^{t_0 + \Delta t} l(x(t), v(t)) dt + T(y(t_0 + \Delta t))$$

Где $y(t_0 + \Delta t)$ - точка, в которой окажется управляемый объект при включении управления v в точке α за время Δt

Переносим функцию T в левую часть и делим на Δt , получаем:

$$\frac{V(y(t_0 + \Delta t)) - V(\alpha)}{\Delta t} \leq \frac{L(t_0 + \Delta t) - L(t_0)}{\Delta t}$$

Раскладывая $y(t_0 + \Delta t)$ в ряд Тейлора, получаем:

$$y(t_0 + \Delta t) = y(t_0) + \dot{y}(t_0)\Delta t + \bar{o}(\Delta t) = \alpha + f(\alpha, v(t_0))\Delta t + \bar{o}(\Delta t)$$

И неравенство можно переписать в виде:

$$\langle V'_x, f(x, v(t)) \rangle - l(x, v) \leq 0 \quad (2.2)$$

То есть, выражение из левой части (2.2) для произвольного управления меньше 0, а для оптимального равно 0. Таким образом, мы получаем уравнение Беллмана:

$$\max_{u(t)} [\langle V'_x, f(x(t), u(t)) \rangle - l(x(t), u(t))] = 0$$

2.2.2 Переход к дискретному случаю

Так как в наше время расчеты управляющих действий и траекторий ведутся на компьютерах, где время дискретно, мы переходим к дискретной постановке задачи и рассмотрим вид изучаемой теории в дискретном случае. Напомним, что исходная задача примет вид:

$$J = \sum_{n=0}^{N-1} l(x_n, u_n) + l_F(x_N) \rightarrow \min_u$$

$$x_{n+1} = f(x_n, u_n)$$

Заметим, что далеко не всегда у нас стоит требование на фиксированное количество шагов, поэтому N часто не фиксировано и в некоторых задачах может равняться бесконечности. В таких случаях слагаемое l_F не имеет смысла.

В таких терминах, функция Беллмана $V(x)$ будет равняться минимальным по всевозможным управлениям общим потерям при условии, что мы начали движение из точки x . Переходную функцию $T(x)$ на практике пропускают.

$$V(x) = \min_u \sum_{n=0}^{+\infty} l(x_n, u_n), x_0 = x$$

Здесь суммирование идет до бесконечности, однако в случае конечных траекторий мы можем просто дополнить нулями оставшиеся награды.

Далее, вспомним как мы выводили уравнение Беллмана. Непрерывность там возникала когда мы переходили к пределу по $\Delta t \rightarrow 0$. Распишем вывод для дискретного случая когда на Δt делить не нужно:

$$V(x_k) - V(x_{k+1}) = l(x_k, u_k)$$

Так как минимально возможное количество шагов во времени равняется 1 шагу, мы получаем левую часть уравнения. Правая часть следует из того что за 1 шаг мы получим только потери за этот шаг. Вообще говоря, ровно 1 шаг делать не обязательно. Так как изначально требований на Δt не было, мы можем выписать уравнение как

$$V(x_k) - V(x_{k+n}) = \sum_{i=k}^{k+n} l(x_i, u_i)$$

2.2.3 Стохастический дискретный случай

Мы вывели дискретное уравнение Беллмана. Однако во всех выкладках мы предполагали окружающую среду строго детерминированной. В реальных задачах такое встречается редко. В большинстве случаев приходится иметь дело с некоторым элементом случайности, когда динамика принимает вид

$$x_{n+1} = f(x_n, u_n, \epsilon)$$

где ϵ - некоторый случайный параметр, взятый из распределения $p(\epsilon)$

В таком случае, функция Беллмана примет вид минимальных ожидаемых потерь с учетом случайности динамики. То есть

$$V(x) = \min_u \mathbb{E}_{x_{1.. \infty} \sim p(\epsilon)} \sum_{n=0}^{+\infty} l(x_n, u_n)$$

И уравнение Беллмана примет вид

$$\begin{aligned} V(x_k) &= \min_u \mathbb{E}_{x_{k+1.. \infty} \sim p(\epsilon)} \sum_{n=k}^{+\infty} l(x_n, u_n) = \min_u \mathbb{E}_{x_{k+1.. \infty} \sim p(\epsilon)} [l(x_k, u_k) + \sum_{n=k+1}^{+\infty} l(x_n, u_n)] = \\ &= \min_u \mathbb{E}_{x_{k+1.. \infty} \sim p(\epsilon)} [l(x_k, u_k)] + \min_u \mathbb{E}_{x_{k+1.. \infty} \sim p(\epsilon)} \left[\sum_{n=k+1}^{+\infty} l(x_n, u_n) \right] = l(x_k, u_k) + \mathbb{E}_{x_{k+1} \sim p(\epsilon)} V(x_{k+1}) \end{aligned}$$

Последнее равенство имеет место, так как мы предполагаем u_k оптимальным.

Таким образом, было выведено уравнение Беллмана в том виде, в котором его можно встретить в большинстве современной литературы [4], [5], [6], [7].

Из вида функций также можно сказать, что аналогичные соотношения имеют место для не оптимального управления. В таком случае все, что изменится - пропадут минимумы из выражений

3 Линейно Квадратичный Регулятор (LQR), уравнения Рикатти

В прошлой главе была кратко описана одна из наиболее популярных сейчас теорий исследования задач оптимального управления. Теперь рассмотрим, как эта теория может быть применена на практике.

Начнем мы с рассмотрения упрощенного случая задачи оптимального управления: линейно-квадратичного регулятора (Linear Quadratic Regulator, LQR).

С задачей LQR вы уже могли сталкиваться в курсе по оптимальному управлению. Суть его состоит в том, что мы накладываем следующие ограничения на вид динамики и функции потерь:

1. зависимость функции динамики от состояния и управления строго линейная:
 $f(x, u) = Ax + Bu$, где $A \in \mathbb{R}^{n \times n}$ и $B \in \mathbb{R}^{n \times m}$
2. зависимость функции потерь от состояния и управления строго квадратичная:
 $l(x, u) = x^T Q x + u^T R u$, где $Q \in \mathbb{R}_{++}^{n \times n}$ и $R \in \mathbb{R}_{++}^{m \times m}$

Таким образом, мы приходим к задачам следующего вида.

В непрерывном случае:

$$J(x(t), u(t)) = \int_{t_0}^{t^1} (x^T Q x + u^T R u) dt \rightarrow \min_{x, u}$$

$$\dot{x} = Ax + Bu$$

В дискретном случае:

$$J = \sum_{n=0}^{N-1} (x_n^T Q x_n + u_n^T R u_n) + x_N^T Q x_N \rightarrow \min_{x, u}$$

$$x_{n+1} = Ax_n + Bu_n$$

Для представленной системы докажем следующую теорему:

Теорема 1: Для задачи линейно-квадратичного регулятора при $N < \infty$ имеют место следующие равенства:

$$J_i^* = \min \sum_{n=i}^N (x_n^T Q x_n + u_n^T R u_n) = x_i^T P_i x_i \quad (3.1)$$

$$P_i = (A - BG_i)^T P_{i+1} (A - BG_i) + G_i^T R G_i + Q, P_N = Q \quad (3.2)$$

$$G_i = (R + B^T P_{i+1} B)^{-1} B^T P_{i+1} A \quad (3.3)$$

$$u_i^* = -G_i x_i, 0 \leq i < N \quad (3.4)$$

Доказательство: Докажем, используя математическую индукцию.

1) Для $i = N$ очевидно, что $J_N = x_N^T Q x_N$

2) Предположим, что $J_{i+1}^* = x_{i+1}^T P_{i+1} x_{i+1}$. Рассмотрим J_i^* . Согласно уравнению Беллмана $J_i^* = V(x_i) = l_i(x_i^*, u_i^*) + V(x_{i+1})$.

Тогда, учитывая определение функции Беллмана

$$J_i^* = \min_{u_i} \{x_i^T Q x_i + u_i^T R u_i + \min_u \sum_{n=i+1}^{N-1} (x_n^T Q x_n + u_n^T R u_n) + x_N^T Q x_N\} = \min_{u_i} \{x_i^T Q x_i + u_i^T R u_i + J_{i+1}^*\}$$

Учитывая предположение индукции, получаем:

$$\begin{aligned} J_i^* &= \min_{u_i} \{x_i^T Q x_i + u_i^T R u_i + x_{i+1}^T P_{i+1} x_{i+1}\} = \\ &= \min_{u_i} \{x_i^T Q x_i + u_i^T R u_i + (A x_i + B u_i)^T P_{i+1} (A x_i + B u_i)\} = \min_{u_i} h(u_i, x_i) \end{aligned}$$

Вычислим минимальное значение J_i и оптимальное u_i взяв производную:

$$\frac{\partial h(u_i, x_i)}{\partial u_i} = 2R u_i + 2B^T P_{i+1} A x_i + 2B^T P_{i+1} B u_i$$

Оптимизируемая функция выпукла, поэтому для минимальности необходимо и достаточно

$$\begin{aligned} \frac{\partial h(u_i, x_i)}{\partial u_i} &= 0 \Leftrightarrow \frac{1}{2} \frac{\partial h(u_i, x_i)}{\partial u_i} = 0 \\ R u_i + B^T P_{i+1} A x_i + B^T P_{i+1} B u_i &= (R + B^T P_{i+1} B) u_i + B^T P_{i+1} A x_i = 0 \\ u_i^* &= -(R + B^T P_{i+1} B)^{-1} B^T P_{i+1} A x_i = -G_i x_i \end{aligned}$$

Подставим u_i^* в выражение для J_i^* , получим:

$$\begin{aligned} J_i^* &= x_i^T Q x_i + x_i^T G_i^T R G_i x_i + (A x_i + B G_i x_i)^T P_{i+1} (A x_i + B G_i x_i) = \\ &= x_i^T Q x_i + x_i^T G_i^T R G_i x_i + x_i^T (A + B G_i)^T P_{i+1} (A + B G_i) x_i = \\ &= x_i^T (Q + G_i^T R G_i + (A + B G_i)^T P_{i+1} (A + B G_i)) x_i = x_i^T P_i x_i \end{aligned}$$

теорема доказана

Уравнения (3.1)-(3.4) из теоремы называются **уравнениями Риккати [8] в дискретном случае [9]** для задачи оптимального управления с конечным горизонтом ($N < \infty$).

Перепишем уравнение (3.2) в более удобном виде:

$$\begin{aligned} P_i &= (A - B G_i)^T P_{i+1} (A - B G_i) + G_i^T R G_i + Q = \\ &= A^T P_{i+1} A - A^T P_{i+1} B G_i - G_i^T B^T P_{i+1} A + G_i^T B^T P_{i+1} B G_i + G_i^T R G_i + Q = \\ &= A^T P_{i+1} A - A^T P_{i+1} B G_i - G_i^T B^T P_{i+1} A + G_i^T (B^T P_{i+1} B + R) G_i + Q = \end{aligned}$$

учитывая (3.3)

$$= A^T P_{i+1} A - A^T P_{i+1} B G_i - G_i^T B^T P_{i+1} A + G_i^T (B^T P_{i+1} B + R) (R + B^T P_{i+1} B)^{-1} B^T P_{i+1} A + Q =$$

$$\begin{aligned}
&= A^T P_{i+1} A - A^T P_{i+1} B G_i - G_i^T B^T P_{i+1} A + G_i^T B^T P_{i+1} A + Q = \\
&= A^T P_{i+1} A - A^T P_{i+1} B G_i + Q = Q + A^T P_{i+1} A - A^T P_{i+1} B (R + B^T P_{i+1} B)^{-1} B^T P_{i+1} A = \\
&= Q + A^T (P_{i+1} - P_{i+1} B (R + B^T P_{i+1} B)^{-1} B^T P_{i+1}) A =
\end{aligned}$$

учитывая тождество Вудберри

$$P_i = Q + A^T (P_{i+1}^{-1} + B^T R^{-1} B)^{-1} A \quad (3.5)$$

Из доказанной теоремы мы очень просто можем получить точное решение задачи LQR для задачи с конечным числом шагов. Однако, возникает следующая проблема: мы не всегда наперед знаем и можем задать это самое количество шагов (гиперпараметр N). В частности, если перед нами стоит задача достижения управляемым дроном точки x_1 из точки x_0 , вычисление гиперпараметра N является весьма трудоемкой и не всегда выполнимой задачей. Проще всего будет переформулировать исходную задачу так чтобы вычисление оптимального N также легло на плечи алгоритма решения. Таким образом, мы приходим к задаче оптимального управления для бесконечного числа шагов:

$$\begin{aligned}
J &= \sum_{n=0}^{\infty} (x_n^T Q x_n + u_n^T R u_n) \rightarrow \min_{x,u} \\
x_{n+1} &= A x_n + B u_n
\end{aligned}$$

Концептуальное отличие заключается в том что в новой постановке мы предполагаем время жизни управляемого объекта бесконечным и решаем задачу, зная что функция потерь будет отрабатывать на каждом шаге до бесконечности.

Оказывается, что для новой постановки также имеют место уравнения Риккати в немного видоизмененной форме.

Теорема 2: Если задача оптимального управления с бесконечным количеством шагов имеет решение, то для него справедливы следующие соотношения:

$$u_i = -G x_i, \forall i \geq 0 \quad (3.6)$$

$$J_i^* = x_i^T P x_i, \forall i \geq 0 \quad (3.7)$$

где P - решение уравнения

$$P = Q + A^T (P^{-1} + B^T R^{-1} B)^{-1} A \quad (3.8)$$

и

$$G = (R + B^T P B)^{-1} B^T P A \quad (3.9)$$

Доказательство проходит тривиальным образом. Теорема 1 была доказана для любых натуральных N . Соответственно, если задача имеет решение, то есть существует хотя бы один набор u такой, что $\sum_{n=0}^{\infty} (x_n^T Q x_n + u_n^T R u_n) < \infty$, тогда можно сказать, что ряд $J_0^*(N)$ сходится при $N \rightarrow \infty$. Так как в теореме 1 мы получили вид $J_0^*(N) = x_0^T P_0 x_0$. Учитывая, что от значения N тут зависит только P_0 , мы получаем, что $J_0^*(N) \xrightarrow{N \rightarrow \infty} x_0^T P_{\infty} x_0$. Это значит, что P_i имеет предел при горизонте

задачи, стремящемся к бесконечности. Делая предельный переход во всех выражениях теоремы 1 и переобозначая P_∞ на P , мы получаем требуемые соотношения для x_0 .

Далее, в силу отсутствия ограничений на выбор x_0 , выведенные соотношения верны для любого x из множества состояний. **теорема доказана**

Таким образом, для решения задачи LQR теперь не обязательно делать обратный прогон, вычисляя по порядку все P_i , после чего делать прогон вперед, вычисляя u_i . Достаточно получить P и G , решив уравнения теоремы 2, и у нас будет алгоритм получения оптимального управления для любого состояния.

4 Переход к RL: алгоритмы Policy и Value Iteration

В предыдущей главе был получен алгоритм аналитического получения оптимального управления для случая когда имеются серьезные ограничения на динамику и потери, которые, вообще говоря, не всегда выполняются. Одним из выходов из данной ситуации будет линеаризация динамики, однако это не всегда реализуемо и лишает нас свободы действий при проектировании функции потерь. В этой главе мы попытаемся разобраться с этими ограничениями и найти способ решения задачи ОУ для произвольных потерь и динамики.

§4.1 Переосмысление уравнений Риккати

Начнем с обобщения механизма уравнения Риккати. Для этого рассмотрим его подробнее. В прошлой главе для случая задачи с потенциально бесконечным количеством шагов мы получили его в следующем виде:

$$P = Q + A^T(P^{-1} + B^T R^{-1} B)^{-1} A$$

Введем оператор Риккати следующим образом:

$$F(X) = Q + A^T(X^{-1} + B^T R^{-1} B)^{-1} A$$

Из двух уравнений выше следует что $P = F(P)$ Во время доказательства теоремы 2 было получено что последовательность P_0 имеет предел при $N \rightarrow \infty$. При этом, легко видеть из теоремы 1 что P_0 получается путем N -кратного применения оператора Риккати к матрице Q . Из двух обозначенных выше фактов следует

Лемма 1: Для любого $\epsilon > 0$ найдется M такое что P_{0M} , полученный не менее чем M -кратным последовательным применением оператора Риккати к матрице Q удовлетворяет следующему неравенству:

$$\|P_{0M} - P\| < \epsilon$$

На основании этой леммы мы можем сказать что решение уравнения Риккати для разрешимой задачи оптимального управления можно получить с любой заданной наперед точностью по следующему алгоритму:

Алгоритм 1

1. Инициализируем $P_{00} = Q$, $n = 0$, $\epsilon > 0$

2. Вычисляем новое значение $P_{0n+1} = F(P_{0n})$
3. Если $\|P_{0n+1} - P_{0n}\| < \epsilon$ - прекращаем, иначе $n := n + 1$ и возвращаемся к шагу 2.

Теперь рассмотрим что именно происходит на шагах 2-3 данного алгоритма.

На шаге 2 мы, основываясь на предыдущей оценке матрицы P получаем новую. При доказательстве теоремы 1 было показано что новое значение матрицы P получается как значение, минимизирующее по управлению в данной точке функцию вида

$$h(u_i, x_i) = x_i^T Q x_i + u_i^T R u_i + (A x_i + B u_i)^T P_{i+1} (A x_i + B u_i)$$

минимум которой, в свою очередь, являлся функцией Беллмана для оптимальной политики в детерминированной среде. Функция Беллмана оценивалась через значение ее же в точке куда мы придем по оптимальной политике через один шаг. Оптимальная же политика высчитывается просто как минимизатор суммы награды за ее выполнение на текущем шаге и ожидаемой награды, которую мы можем получить в состоянии куда по ней придем.

Переходя к пределу по количеству шагов мы, помимо прочего, отвызываемся от предопределенного плана на то когда и в каком состоянии мы должны оказаться, тем самым получаем универсальную формулу решения LQR в произвольной точке.

Таким образом, алгоритм 1 можно расписать следующим образом:

Алгоритм 1-Р

1. Получаем начальную аппроксимацию $P = Q$ как минимизатор функции Беллмана в тривиальном случае когда в начальный момент времени объект находится в конечном состоянии.
2. Получаем оптимальную политику действия для точки, находящейся в 1 действии от конечного состояния как минимизатор функции Беллмана в этой точке. На основании теорем 1 и 2 её можно получить по формулам (3.6) - (3.9), где P берется с предыдущего шага.
3. На основании полученной политики получаем новое значение P что, как было показано выше, эквивалентно получению значения функции Беллмана для текущей точки.
4. Получаем оптимальную политику действия для точки, находящейся в 2 действиях от целевого состояния как минимизатор функции Беллмана в этой точке. На основании теорем 1 и 2 её можно получить по формулам (3.6) - (3.9), где P берется с предыдущего шага.
5. На основании полученной политики получаем новое значение P что, как было показано выше, эквивалентно получению значения функции Беллмана для текущей точки.
6. продолжаем до сходимости

В случае с потенциально бесконечным числом шагов ($N = \infty$) у нас по сути отсутствует конечное состояние, и мы всегда предполагаем, что объект может жить вечно. Как следует из леммы 1 и теоремы 2, тогда алгоритм выше сойдется к пределу P что эквивалентно сходимости аппроксимаций функции Беллмана к значению функции Беллмана $V(x)$ для каждой точки. Политика в каждой точке вычисляется как минимизатор функции Беллмана.

Данная интерпретация алгоритма вычисления оптимального управления позволяет нам выделить в этом алгоритме те моменты, где мы пользовались линейным видом динамики и квадратичным видом функции потерь, и найти способ решить задачу без этих ограничений.

§4.2 Переход к динамике и потерям произвольного вида

Перейдем теперь к задаче оптимального управления без предположений о виде динамики и потерь. Она будет выглядеть следующим образом:

$$J(x, u) = \sum_{n=1}^{\infty} l(x_n, u_n) \rightarrow \min_{x, u}$$

$$x_{n+1} = f(x_n, u_n, \epsilon)$$

Но мы будем рассматривать ее, приняв ряд договоренностей, принятых в современном RL[3].

1. При решении задачи идет не минимизация суммарных потерь, а максимизация суммарной награды.
2. На сумму наград накладывается дисконтирование.

Таким образом, задача выглядит следующим образом:

$$J(x, u) = \sum_{n=0}^{\infty} \gamma^n l(x_n, u_n) \rightarrow \max_{x, u}, 0 < \gamma < 1$$

$$x_{n+1} = f(x_n, u_n, \epsilon)$$

В теории уравнений Беллмана для нее изменится следующее:

1. Все минимумы станут максимумами.
2. Перед оценкой функции Беллмана на следующем шаге добавится множитель γ .

В качестве решения хотелось бы найти алгоритм, аналогичный алгоритму 1, который бы позволил найти решение задачи.

Для этого обратимся к алгоритму 1-Р, расшифровывающему алгоритм 1. Предположения о виде динамики и функции потерь использовались на следующих этапах:

1. при получении начального значения P для которого доказана сходимость алгоритма

2. при явном вычислении оптимальной политики как минимизатора функции Беллмана
3. при получении нового значения P как значения, для которого будет верно уравнение Беллмана.

Как было выяснено в разделе 4.1, алгоритм 1 эквивалентен итеративному поиску значения функции Беллмана для всех состояний из X и вычислению управления как минимизатора этой функции. Специфический вид динамики и потерь тут играл роль при явном вычислении управления и функции Беллмана, а также гарантировал, что если мы имеем дело с непрерывным пространством состояний X , функция Беллмана будет всегда иметь вид $x^T P x$ при любом x для P , полученного как предел последовательности P_{0i} . Для случая произвольной динамики и потерь таких гарантий у нас нет, но они и не являлись основообразующими для алгоритма.

Попробуем переписать алгоритм 1 без предположений о динамике и потерях:

Алгоритм 2:

1. получить начальное приближение функции Беллмана $V(x)$ для всех $x \in X$
2. получить для всех x оптимальное управление $u(x)$ как максимизатор функции Беллмана $V(x) = l(x, u) + \gamma \mathbb{E}_{p(\epsilon)} V(x')$, где x' - состояние в которое мы перейдем при выполнении управления u в состоянии x .
3. получить на основании нового управления новое приближение функции Беллмана.
4. повторять до сходимости.

Для реализации этого алгоритма нам нужно получить для функции Беллмана уравнение, аналогичное уравнению (3.8) и найти итеративный способ решения. При наличии такого мы сможем реализовать пункт 1 и 3 из алгоритма 2, после чего заняться поиском управления.

Оптимальное P мы получали как решение уравнения (3.8) путем итеративного применения оператора Риккати. Попробуем найти такой же метод получения V .

Введем оператор Беллмана следующим образом: $W(V) = l(x, u) + \gamma \mathbb{E}_{p(\epsilon)} V(x')$. Имеет место следующая теорема:

Теорема 3: оператор Беллмана является сжимающим отображением для дискретного пространства состояний.

Доказательство:

$$W(V) = l(x, u) + \gamma \mathbb{E}_{p(\epsilon)} V(x') =$$

Учитывая, что пространство состояний дискретно по условию теоремы, распределение $p(\epsilon)$ также дискретно, мы можем записать:

$$W(V) = l(x, u) + \gamma \sum_{\epsilon} p(\epsilon) V(x'_\epsilon) = l(x, u) + \gamma D_\epsilon V_\epsilon$$

где D_ϵ - вектор вероятностей перейти во всевозможные состояния x , V_ϵ - вектор значений функций Беллмана для всех x , соответствующих значению ϵ . В формуле выше считается что каждое значение ϵ порождает какое-то следующее состояние x' .

$$\|W(V_1) - W(V_2)\| = \|l(x, u) + \gamma D_\epsilon V_1 - l(x, u) - \gamma D_\epsilon V_2\| = \|\gamma D_\epsilon V_1 - \gamma D_\epsilon V_2\| \leq \gamma \|D_\epsilon\| * \|V_1 - V_2\|$$

Чтобы $W(V)$ было сжимающим отображением, нужно показать что $\|P_\epsilon\| \leq 1$. Для произвольной нормы это, вообще говоря, неверно. Воспользуемся тем фактом, что на данный момент мы норму используем только в доказываемой теореме и в определении сходимости P , где ограничений на норму не накладывалось. Договоримся о виде нормы.

$$\|P_\epsilon\| = \|P_\epsilon\|_\infty = \max_i |P_{\epsilon i}|$$

Так как P_ϵ - это вектор вероятностей, $\|P_\epsilon\|_\infty \leq 1$

Тогда

$$\|W(V_1) - W(V_2)\| \leq \gamma \|P_\epsilon\| * \|V_1 - V_2\|$$

где $\gamma \|P_\epsilon\| < 1$, следовательно оператор Беллмана - сжимающее отображение.

Теорема доказана.

Теорема 3 значит что если мы будем применяя оператор Беллмана последовательно обновлять значения функции Беллмана во всех состояниях и брать политику как ее максимизатор, в какой-то момент мы сойдемся к оптимальному решению.

Таким образом, результатом данного раздела является алгоритм Iterative Policy Evaluation:

1. Инициализируем δ . Для всех состояний x инициализируем $V(x)$,
2. Для всех состояний x и оптимальной политики u : $v = V(x)$, $V(x) = r(x, u) + \gamma \mathbb{E}_{p(\epsilon)} V(x')$, $\Delta_x = |v - V(x)|$
3. Повторяем шаг 2 хотя бы для одного x $\Delta_x > \delta$

§4.3 Policy и Value Iteration

Итак, мы провели все подготовительные работы и готовы сформулировать первые два метода из области обучения с подкреплением.

Policy Iteration:

1. Инициализируем $V(x)$, $u(x)$.
2. С помощью Iterative Policy Evaluation обновляем значения $V(x)$.
3. Для всех x обновляем $u(x) = \operatorname{argmax}_u \{r(x, u) + \gamma \mathbb{E}_{p(\epsilon)} V(x')\}$
4. Если на предыдущем шаге хотя бы одно управление изменилось, то возвращаемся к шагу 2.

Учитывая вид управления, мы можем объединить шаги 2 и 3 и получить еще один алгоритм.

Value Iteration:

1. Инициализируем $V(x)$, $u(x)$.
2. Обновляем значения $V(x)$ по формуле: $V(x) = \max_u \{r(x, u) + \gamma \mathbb{E}_{p(\epsilon)} V(x')\}$

3. Если на предыдущем шаге хотя бы одно управление изменилось, то возвращаемся к шагу 2.

Разумеется, в этих алгоритмах мы делаем сильное предположение о виде пространства состояний X : оно должно быть дискретным. Как снять это ограничение, будет рассказано в следующей главе.

=====To be continued=====

Список литературы

- [1] [Richard Bellman. Dynamic programming](#)
- [2] [Лекция Орлова про уравнение Беллмана](#)
- [3] [Richard S. Sutton and Andrew G. Barto, Reinforcement Learning, глава 4](#)
- [4] [Asynchronous Methods for Deep Reinforcement Learning](#)
- [5] [Trust Region Policy Optimization](#)
- [6] [Proximal Policy Optimization Algorithms](#)
- [7] [Soft Actor-Critic](#)
- [8] [Riccati Equations in Optimal Control Theory](#)
- [9] [New Forms of Riccati Equations and the Further Results of the Optimal Control for Linear Discrete-Time Systems](#)
- [10] [Simple Statistical Gradient-Following Algorithms for Connectionist Reinforcement Learning](#)
- [11] [SLIP Nature Embodied Robust Quadruped Robot Control](#)
- [12] [Tello Leg: The Study of Design Principles and Metrics for Dynamic Humanoid Robots](#)
- [13] [Prioritized Motion-Force Control of Constrained Fully-Actuated Robots: Task Space Inverse Dynamic](#)
- [14] [Online Trajectory Optimization for Dynamic Aerial Motions of a Quadruped Robot](#)
- [15] [Пример про sim2real](#)
- [16] [Лекция про A2C](#)
- [17] [Статья про связь VI и PI с уравнения Риккати](#)